# 单词预测项目报告

项目名称 \_\_\_\_\_下一个单词预测器

组员姓名 黄宇威、王润鹏、李爽、熊腾

报告时间 \_\_\_\_\_2022年8月23日

# 基于自然语言处理的单词预测器

### 黄宇威

#### 2022年8月23日

#### 摘要

手机上的键盘如何知道您接下来 要输入什么?本系统旨在设计一个单 词预测器,根据输入的单词或词组给 出下一个单词的建议,达到节省时间 的目的。信息时代的不断发展使计算 机人工智能的开发与应用越来越广泛。 本系统基于自然语言处理中的分词技 术,采用三种语言模型,最终实现单 词预测的功能。

## 1 项目介绍

单词预测是一种自然语言处理 - NLP 应用程序,通过大量的短句或者词组训练模型,来实现单词预测,本文将介绍如何开发一个单词预测器,首先最重要的是选择语言模型,这里我们将采用三种模型用于开发: N-gram 自然语言模型、LSTM(长短期记忆人工神经网络)、NNLM神经网络语言模型。目的是为了对比不同方法的预测结果差异变化。具体代码见:github

### 2 数据介绍

本文训练数据来源于github,数据采用txt文件格式存储,包含上万个英文短句以及词组,每个单词之间以空格符隔开,

短句用行的形式区分。部分数据示例如下 图:

Now a silenter vote 10 U.S. 100; 100 terms "fixes matter" and "fixes attender" as promotion. 0
On a silent vote "impresses were explicitly used by speared of the distance Street of Technologies (100 terms). 100 terms of the silent vote attender to the si

## 3 算法细节

#### 3.1 LSTM 神经网络

#### **3.1.1** LSTM 算法原理

LSTM 神经网络是 RNN 网络的衍生物,是特殊的循环神经网络,能够克服RNN 网络的缺点,用来处理长时依赖问题,经过大量的研究证明 LSTM 神经网络在时间序列预测问题上获得了更进一步的成功。LSTM 网络的结构与 RNN 相似,处理模块 A 更加复杂,标准 LSTM 结构如下图所示:




图 3.1: LSTM 网络标准结构

LSTM 网络结构细节解析:

- 1. 遗忘门(Forget Gate),是 LSTM 的忘记阶段,对上一节点的输入信息选择性忘记,由一个被称为"遗忘门限层"的 sigmoid 层决定。根据上一时刻的输出和当前输入为单元状态的每一个数字计算 0 到 1 之间的数字,0 表示"完全抛弃",1 表示"完全保留"。
- 2. 输入门(Input Gate),是 LSTM 的记忆阶段,随着时间不断更新状态值,留下有用的状态值。过程分为两个部分,首先 sigmoid 层决定需要更新的数值,其次 tanh 层创建向量,再结合二者创建一个状态更新。
- 3. 通过简单的线性交互,更新旧单元状态,输入到新单元状态,即来完成对信息的更新。前两个部分已经决定需要哪些信息,结合遗忘门和输入门的信息得到更新后的单元状态。
- 4. 输出门(Output Gate),是 LSTM 的输出阶段,建立在单元状态的基础上,经遗忘门和输入门对信息的不断筛选过滤,最终决定当前状态的输出。

#### 3.1.2 LSTM 算法实现步骤

1. 预处理数据-读取文本,使用word\_tokenize函数将句子分为单个单词。

代码如下:

- 1 # 读取文件
- 2 with open(path, encoding=' utf-8') as f:
- sents = f.read()

2. 使用fit\_on\_texts函数分词后,在用texts\_to\_sequences函数对序列进行重新编码

3. 获得编码形式的序列后,通过将序列 拆分为输入和输出标签来定义使用前 三个词作为输入,最后一个词作为模 型要预测的标签

4. 将目标标签序列通过to\_categorical函数转换为 one-hot 向量,即 0 和 1 的组合

```
1 # 将类别向量转换为二进制
2 train_targets =
    to_categorical(
    train_targets,
    num_classes=
    vocabulary_size)
```

5. 训练LSTM模型,一共有 5 层的Sequential模型:一个 Embedding 层、两个 LSTM 层和两个 Dense 层。在我们模型的输入层(即嵌入层)中,输入长度设置为序列的大小,在本例中为 3

```
1 #模型创建或加载
2 def train_model(
       vocabulary_size,
       train_inputs,
       train_targets , seq_len):
     if not os.path.exists("
        mymodel.h5"):
4 # 创建模型
     model = Sequential()
 6
     model.add(Embedding(
         vocabulary_size,
         seq_len, input_length=
         seq_len))
     \mathbf{model} add (LSTM(50,
 7
         return_sequences=True))
8
     \mathbf{model} \cdot \mathbf{add} (\mathbf{LSTM}(50))
9
     \mathbf{model}.\mathbf{add}(\mathbf{Dense})
         activation='relu'))
10
     model.add(Dense(
         vocabulary_size,
         activation='softmax'))
11 # compile network
     model.compile(loss='
12
```

```
categorical_crossentropy
        ', optimizer='adam',
        metrics=['accuracy'])
13
     model. fit (train_inputs,
        train_targets, epochs
        =500, verbose=1)
14
     model.save("mymodel.h5")
     print('模型创建完成')
15
   else:
16
17
    # 加载模型
18
     print('加载模型')
19
     model = load_model("
        mymodel. h5")
20
    return model
```

6. 输入测试数据,并从softmax函数中获取三个最可能的单词

```
input_text = input().strip()
     .lower()
2 \quad encoded\_text = tokenizer.
     texts_to_sequences([
     input_text])[0]
3 # 对上面生成的不定长序列进行补全
4 pad_encoded = pad_sequences
     ([encoded_text], maxlen=
     seq_len, truncating='pre'
5 print("输入:", input_text)
6 l = len(tokenizer.index_word
7 # 开始预测
8 for i in (model.predict(
     pad_encoded)[0]).argsort
     () [-3:][::-1]:
    pred\_word = tokenizer.
9
       index_word[i]
```

print("候选词:", pred\_word)

#### N-gram 自然语言模型 3.2

#### 3.2.1 N-gram 算法原理

N-gram是指给定的文本或语音序列中 包含N个最小分割单元的连续序列。最小 分割单元可以是音素、音节、字母、字或 者是一些根据具体应用而自定义的基本对 (BasicPairs).

N-gram实际上是N-1阶马尔可夫语 言模型的表示。假设一列随机变量S1, S2, ···, Sm中, 如果其中任何一个随机 变量Si发生的概率只与其前面的N-1个变 量Si-1, Si-2,…, Si-n+1有关, 即:

$$P(S_{i} | S_{i-n+1} S_{i-n+2} \cdots S_{i-2} S_{i-1}) = P(S_{i} | S_{1} S_{2} \cdots S_{i-2} S_{i-1})$$

则称之为N-1阶马尔可夫过程。Ngram模型就是将所有连续可重叠的N个 词作为一个单元,并将其假设为一个N-1阶马尔可夫过程。这种假设的意义在于, 第N个词的出现只与前N-1个词相关,而与 其他任何词都不相关。整个句子的概率是 各个词出现概率的乘积,而这些单个词的 概率可由语料库中统计N个词同时出现的 次数得到。

N-gram理论在信息检索研究中主要应 用于检索预处理、索引、语种识别等先导 性工作,包括语音和文本分析领域。在语 音分析领域, Torres-Carrasquillo等使用音 素标记化结合N-gram将语言模型化来进行 语言识别,得到稳定的结果。

#### 3.2.2 N-gram 算法实现步骤

每个唯一的单词作为键,其后面的 单词列表作为值被添加到我们的字 典lookup\_dict 中

代码如下:

```
1 def add_document(self,
                                       string):
                                     self.lookup_dict.clear()
                                  3
                                     with open (string, encoding=
                                         utf-8' as f:
                                        sents = f.read()
                                  4
                                     preprocessed_list = self.
                                  5
                                        _preprocess(sents)
                                     pairs = self.
                                        __generate_tuple_keys(
                                        preprocessed_list)
                                     #将生成的词组加入字典中
                                  8
                                     for pair in pairs:
                                        self.lookup_dict[pair
                                  9
                                            [0]].append(pair [1])
                                     pairs2 = self.
                                 10
                                        __generate_2tuple_keys(
                                        preprocessed_list)
                                     for pair in pairs2:
                                 11
                                         self.lookup_dict[tuple([
                                 12
                                           pair [0], pair [1]])].
                                           append(pair[2])
                                     pairs3 = self.
                                 13
                                        __generate_3tuple_keys(
                                        preprocessed_list)
                                     for pair in pairs3:
                                 15
                                         self.lookup_dict[tuple([
                                           pair [0], pair [1],
                                           pair [2]]) ].append(
                                           pair [3])
                                 16
1. 读取数据,为每个唯一单词创建对, 17 def _preprocess(self, string
```

 判断输入的字符是几个单词,然后从字 典中查找下一个单词

```
1 # 根据空格符分隔词组
    tokens = string.split("")
    if len(tokens) = 1:
   # 根据一个单词查找
4
    txt = self.oneword(string)
5
    elif len(tokens) = 2:
    # 根据两个单词查找
7
8
      txt = self.twowords(
        \mathbf{string}.\,\mathbf{split}\,(\,"\ ")\,)
    elif len(tokens) = 3:
9
10 # 根据三个单词查找
11
      txt = self.threewords(
        string.split(""))
    elif len(tokens) > 3:
12
13
      txt = self.morewords(
        string.split(""))
14
15
16
  #根据一个单词查找字典中的候选词
    def oneword(self, string):
17
   #统计出现次数最多的候选词
19
      return Counter(self.
        lookup_dict[string]).
        most\_common() [:10]
20 #根据两个单词查找字典中的候选词
    def twowords(self, string):
```

#### 3.3 NNLM神经网络语言模型

#### 3.3.1 NNLM 算法原理

NNLM是 通 过 第t个 词 前 的n-1个 词,预测每个词在第t个位置出现的概率,即: $f(w_t, \dots, w_{t-n+1}) = \hat{P}(w_t|w_1^{t-1})$ 

其中f > 0,即预测出的结果都是大于0的,且预测结果的和为1,NNLM包含一个三层的神经网络,具体模型结构如下:




图 3.2: NNLM 模型结构

模型一共三层,第一层是映射层,将n个单词映射为对应word embeddings的拼接,其实这一层就是MLP的输入层;第二层是隐藏层,激活函数用tanh;第三层是输出层,因为是语言模型,需要根据前n个单词预测下一个单词,所以是一个多分类器,用softmax。

1. 读取数据,添加到词典word\_list中,并 为每个单词创建下标索引

```
1 #按照空格分词,
2 #统计 的分词的个数 sentences
3 word_list = " ".join(
    sentences).split()
4 #去重 统计词典个数
5 word_list = list(set(
    word_list))
6 word_dict = {w: i for i, w
    in enumerate(word_list)}
7 number_dict = {i: w for i, w
    in enumerate(word_list)}
```

#### 2. 创建NNLM模型

```
1 \# Model
2 class NNLM(nn. Module):
    def __init__(self):
3
      super(NNLM, self).
4
         __init__()
    # 矩阵Q (V x m)
5
    #表示的字典大小word,
6
    # m 表示词向量的维度
7
      self.C = nn.Embedding(
8
         n_{class}, m)
9
      self.H = nn.Linear(n_step)
          * m, n_hidden, bias=
         False) ###
10
      self.d = nn.Parameter(
         torch.ones(n_hidden))
11
      self.U = nn.Linear(
         n_hidden, n_class,
         bias=False)
12
      self.W = nn.Linear(n_step)
          * m, n_{class}, bias=
         False)
```

```
self.b = nn.Parameter(
         torch.ones(n_class))
14
15
    def forward(self, X):
16
      X = self.C(X) \# X : 
         batch\_size, n\_step, m
      X = X.view(-1, n\_step * m)
17
         ) \# /batch\_size,
         n_step * m
      tanh = torch.tanh(self.d)
18
         + self.H(X)) # /
         batch\_size, n\_hidden
      output = self.b + self.W(
19
         X) + self.U(tanh) # /
         batch_size, n_class
20
      return output
```

#### 3. 构建输入数据和目标标签

```
1 def make_batch():
    input_batch = []
    target_batch = []
3
4
    for sen in sentences:
      word = sen.split() \#space
5
          tokenizer
6
      input = [word\_dict[n] for]
          n in word[:-1]
      target = word_dict [word
7
         [-1]
8
      input_batch.append(input)
9
      target_batch.append(
         target)
    return input_batch,
10
       target_batch
```

4. 将构建的输入数据和目标标签转成tensor形式

- 1 #模型输入## tensor 形式
- input\_batch = torch.
  LongTensor(input\_batch)
- 3 target\_batch = torch. LongTensor(target\_batch)
- 5. 训练模型并预测数据

```
1 # 训练模型迭代次
                   5000
    for epoch in range (5000):
   #梯度归零
3
      optimizer.zero_grad()
4
      output = model(
5
         input_batch)
6 \# output : \lceil batch\_size \rceil
      n_{-}class, target_{-}batch:
      \int b a t c h_s i z e \int
      loss = criterion (output,
         target_batch)
      if (epoch + 1) \% 1000 ==
8
          0:
        print ( 'Epoch: ', '%04d'
9
           \% (epoch + 1), 'cost
             =', '\{:.6 f\}'. format
            (loss))
    # 反向传播计算每个参数的梯度值
10
11
         loss.backward()
   # 每一个参数的梯度值更新
12
13
        optimizer.step()
       # 预测
14
    predict = model(input_batch
15
       ) . data.max(1, keepdim=
       True) [1]
```

### 4 算法结果

#### 4.1 LSTM神经网络算法结果

1. 预处理数据

['how', 'many', 'people', 'live', 'in', 'atlanta', 'georgia', 'atlanta',

2. 使用fit\_on\_texts函数分词后,在用texts\_to\_sequences函数对序列进行重新编码

OPHNI: (Thow', 'many', 'people', 'five'), ('many', 'people', 'five', 'in'), ('people', 'five', 'in', 'atlanta'), ('people', 'five', 'in', 'atlanta'), ('people', 'five', 'in', 'atlanta'), ('people', 'five', 'in', 'atlanta'), ('people', 'five', 'five',

3. 将编码序列拆分为输入和输出标签(仅 打印第一组)

```
拆分前 [[ 6 13 22 15]]
拆分后输入目标标签 [[ 6 13 22]]
拆分后输出(预测)目标标签 [15]
```

4. 将目标标签序列转换为 one-hot 向量

5. 训练LSTM模型

6. 预测结果

```
输入: how many people
1/1 [------] - 1s 1s/step
候选词: died
候选词: visit
候选词: live
```

# 4.2 N-gram自然语言模型算法 结果

1. 预处理数据-读取文本,使用word\_tokenize函数将句子分为单个单词。

```
['how', 'many', 'people', 'live', 'in', 'atlanta', 'georgia', 'atlanta',
```

2. 创 建 键 值 对, 添 加 进 字 典lookup\_dict中

```
('how': ['are', 'many', 'are'], 'are': ['you', 'your'],
   'you': ['how'], 'many': ['days'], 'days': ['since'],
   'since': ['we'], 'we': ['last'], 'last': ['met'], 'met': ['how'],
   'your': ['parents']
}

{
   ('how', 'are'): ['you', 'your'],
   ('how', 'many'): ['days'],
   ('many', 'days'): ['since'],
   ('how', 'are', 'you'): ['how'],
   ('how', 'many', 'days'): ['since'],
}
```

3. 根据输入的单词预测,测试输入一个 单词,两个单词,三个单词的结果, 候选词的顺序以训练次数排序

```
#8A: low MARI: ("many, 1878), Cdaf., 409, Cdoor, 300, Canat', 300, Clif., 222, Cdaf., 120), Cdof., 121), Clong., 140), Cany', 122, Cdaf., 80)]

#8A: how many
#8A: (Compute, 181), Connection, 181, Connection, 201, Connect, 202, Connect, 202, Connection, 202, Con
```

4. 上述测试数据how many输入了两次, 再次输入how时, many次数多了两次

```
输入: how
候选词: [('many', 1577),
```

# 4.3 NNLM神经网络语言模型 算法结果

1. 读取数据,添加到词典word\_list中,并 为每个单词创建下标索引

```
vord_list: ['countries', 'states', 'episodes', 'people', 'manny', 'seasons', 'how']
vord_dict: ['countries': 0, 'states': 1, 'episodes': 2, 'people': 3, 'many': 4, 'seasons': 5, 'how': 6]
number_dict: (0: 'countries', 1: 'states', 2: 'episodes', 3: 'people', 4: 'manny', 5: 'seasons', 6: 'how')
```

2. 构建输入数据和目标标签

```
imput_batch [[6, 4], [6, 4], [6, 4], [6, 4]]
target_batch [3, 0, 2, 5, 1]
```

3. 输入数据和目标标签转成tensor形式

4. 训练数据集以及每1000次的CrossEntropyLoss数据

```
Epoch: 1000 cost = 0.142009

Epoch: 2000 cost = 0.020039

Epoch: 3000 cost = 0.006503

Epoch: 4000 cost = 0.002758

Epoch: 5000 cost = 0.001322
```

5. 根据输入单词进行预测

```
输入: [['how', 'many']]
候选词 ['people', 'countries', 'episodes', 'seasons', 'states']
```

# 参考文献

- [1] 刘甲, 孙德山. 基于注意力机制和LSTM网络的股价预测[J]. 应用数学进展, 2021, 10(12): 4379-4385.
- [2] 王昊, 李思舒, 邓三鸿. 基于N-Gram的 文本语种识别研究[J]. 现代图书情报 技术, 2013, (4): 54-61. Wang Hao, Li Sishu, Deng Sanhong. Study on Text Language Recognition Based on N-Gram. New Technology of Library and Information Service, 2013, (4): 54-61.
- [3] 段字锋, 鞠菲. 基于N-Gram的专业领域中文新词识别研究[J]. 现代图书情报技术, 2012, 28(2): 41-47. Duan Yufeng, Ju Fei. Research on Chinese New Word Recognition in Specialized Field Based on N-Gram. New Technology of Library and Information Service, 2012, 28(2): 41-47.